Modelamiento espacial bayesiano de las desigualdades en la letalidad por COVID-19

Replicación de Polo et al. (2022)

Walys Vera Herrera
Análisis Bayesiano de Datos – Prof. Johanna Marcela Orozco Castañeda
Pregrado en Estadística, Universidad de Antioquia

9 de noviembre de 2026

Resumen

Entre marzo y octubre de 2020, la letalidad por COVID-19 en Colombia fue muy distinta entre departamentos, a pesar de que las medidas de control fueron las mismas en todo el país. Con una tasa nacional de 3.4 % (28 882 muertes), la letalidad bruta varió entre 1.4 % en Vaupés y 6.6 % en Córdoba. Este trabajo replica el análisis de Polo et al. (2022), que relaciona esa letalidad con las cinco dimensiones del Índice de Pobreza Multidimensional (salud, educación, niñez y juventud, trabajo y vivienda) en los 33 departamentos. Se ajustó una regresión Poisson bayesiana con efectos aleatorios espaciales con priori CAR de Leroux, estimada con un algoritmo de Metropolis dentro de Gibbs. Solo la dimensión educativa mostró una asociación clara: un aumento de una desviación estándar se asoció con un 68 % más de riesgo de morir (RR = 1.68; IC 95 %: 1.14–2.43), consistente con el artículo original. En cambio, no se reprodujeron los efectos de vivienda, salud ni de niñez y juventud; la vivienda mostró incluso una asociación negativa (RR = 0.65; IC 95 %: 0.43–1.02), contradiciendo el principal hallazgo del artículo, posiblemente por la alta correlación entre las dimensiones. La dependencia espacial fue débil ($\rho = 0.18$) y sensible a la priori. Los resultados muestran la utilidad del enfoque bayesiano con pocas unidades de análisis, pero indican que la relación entre pobreza multidimensional y letalidad es menos robusta de lo reportado originalmente.

Palabras clave: estadística bayesiana, modelo CAR, datos de área, MCMC, COVID-19, pobreza multidimensional, replicación.

1. Introducción

La pandemia de COVID-19 puso a prueba los sistemas de salud de todos los países. En Colombia, entre el 16 de marzo y el 4 de octubre de 2020, se reportaron 28 882 muertes y la letalidad nacional, es decir, la proporción de casos resueltos que terminaron en muerte, fue de 3.4 %. Sin embargo, esta cifra no fue igual en todo el territorio: entre departamentos la letalidad bruta osciló entre 1.4 % en Vaupés y 6.6 % en Córdoba (Polo et al., 2022). Esta diferencia llama la atención porque las principales medidas de control, como el aislamiento preventivo obligatorio, fueron definidas mediante decretos nacionales y aplicadas de manera general en todo el territorio colombiano. Aunque hubo medidas locales complementarias y diferencias en la capacidad hospitalaria, la heterogeneidad en la letalidad no parece explicarse principalmente por diferencias en las políticas, sino que debe buscarse en las condiciones sociales y económicas de cada departamento.

Una explicación posible es la pobreza. La pobreza es un fenómeno multidimensional que no se limita al ingreso, sino que incluye carencias en el acceso a la salud, la educación, el empleo y las condiciones de la vivienda (Alkire y Santos, 2014). En Colombia, el Departamento Administrativo Nacional de Estadística (DANE) mide la pobreza mediante el Índice de Pobreza Multidimensional (IPM), compuesto por cinco dimensiones: salud, educación, niñez y juventud, trabajo y vivienda (DANE, 2020). Cada una de estas dimensiones puede afectar factores relacionados con la prevención, el acceso a servicios de salud y la atención oportuna de los casos de COVID-19; por ejemplo, la falta de aseguramiento en salud puede retrasar la atención médica, y la falta de agua potable o el hacinamiento dificultan medidas básicas de prevención, como el lavado de manos.

Para estudiar esta relación es necesario tener en cuenta que los departamentos no son unidades aisladas. Los departamentos vecinos comparten características que no siempre se pueden medir, como el clima, la infraestructura hospitalaria o la movilidad de la población, por lo que es razonable esperar que sus riesgos se parezcan. Los modelos espaciales bayesianos permiten incorporar esta dependencia a través de la distribución a priori de unos efectos aleatorios, como en el modelo autorregresivo condicional (CAR) propuesto por Leroux et al. (2000). Además, el enfoque bayesiano es especialmente útil cuando se cuenta con pocas unidades de análisis, como en este caso con 33 departamentos, ya que permite cuantificar

la incertidumbre de todos los parámetros a partir de su distribución posterior.

El objetivo de este trabajo es replicar el análisis de Polo et al. (2022), quienes estudiaron la asociación entre las dimensiones del IPM y la letalidad por COVID-19 en Colombia mediante un modelo espacial bayesiano CAR de Leroux. Para ello, primero se presentan los fundamentos del modelo; luego se ajusta con los datos publicados en el artículo, mediante un algoritmo de Metropolis dentro de Gibbs implementado por la autora, y se evalúa la convergencia de las cadenas, la sensibilidad a la distribución a priori y la comparación con un modelo sin efectos aleatorios. Finalmente, se contrastan los resultados con los del artículo original y se discuten sus diferencias.

2. Fundamentos teóricos

2.1. Modelos espaciales bayesianos

Un modelo espacial bayesiano es un modelo jerárquico en el que la dependencia entre observaciones cercanas se introduce mediante la distribución a priori de un vector de efectos aleatorios espaciales $\boldsymbol{\phi}$. Si $\boldsymbol{y}$ son los datos y $\boldsymbol{\psi}$ los demás parámetros del modelo (en este trabajo, los coeficientes $\boldsymbol{\beta}$ y los parámetros τ^2 y ρ de la priori espacial), la inferencia se basa en la posterior conjunta

$$p(\boldsymbol{\phi}, \boldsymbol{\psi} \mid \boldsymbol{y}) \;\propto\; p(\boldsymbol{y} \mid \boldsymbol{\phi}, \boldsymbol{\psi}) \quad \underbrace{p(\boldsymbol{\phi} \mid \boldsymbol{\psi})}_{\text{estructura espacial}} \quad p(\boldsymbol{\psi}) \tag{1}$$

(Banerjee et al., 2014). Esta estructura puede definirse sobre puntos de una superficie continua (datos geoestadísticos) o sobre regiones que dividen el territorio (datos de área); este trabajo usa datos de área.

2.2. Datos de área y riesgo relativo

Definición 1 (Datos de área y matriz de vecindad)**.** Los datos de área son conteos $Y_1, \ldots, Y_K$ agregados sobre K regiones que forman una partición del territorio (Banerjee et al., 2014). La estructura espacial se representa con la matriz $W = (w_{kj})_{K\times K}$, con $w_{kj} = 1$ si las regiones $k \neq j$ comparten frontera y $w_{kj} = 0$ en otro caso; $n_k = \sum_j w_{kj}$ es el número de vecinos de k y $D_W = \operatorname{diag}(n_1, \ldots, n_K)$.

Definición 2 (Conteos esperados y riesgo relativo)**.** Sea N_k la población en riesgo de la región k y $\pi_0 = \sum_k Y_k / \sum_k N_k$ la tasa global del territorio. El número de eventos **esperados** en la región k es el que ocurriría si esta tuviera la tasa global (estandarización indirecta):

$$E_k = N_k\, \pi_0, \qquad \text{de modo que} \quad \textstyle\sum_k E_k = \sum_k Y_k. \tag{2}$$

El **riesgo relativo** $R_k > 0$ se define por $\mathbb{E}(Y_k) = E_k R_k$, y su estimador directo es la razón estandarizada $\hat{R}_k = Y_k / E_k$ (Banerjee et al., 2014).

Así, $R_k = 1$ indica que la región se comporta como el total, y $R_k > 1$ ($R_k < 1$) que tiene más (menos) eventos de los esperados. Como E_k se calcula antes de ajustar el modelo, se trata como una constante conocida. El estimador $\hat{R}_k$ tiene varianza $\operatorname{Var}(\hat{R}_k) = R_k / E_k$ bajo un modelo Poisson, de modo que en regiones con E_k pequeño es muy inestable. Además, regiones vecinas comparten factores no medidos y sus R_k no son independientes. El modelo espacial bayesiano atiende ambos problemas.

2.3. Estructura jerárquica del modelo

Definición 3 (Modelo espacial bayesiano para conteos de área)**.** Sean $\boldsymbol{x}_k \in \mathbb{R}^p$ covariables de la región k y $\boldsymbol{\phi} = (\phi_1, \ldots, \phi_K)^\top$ efectos aleatorios espaciales. El modelo se especifica en tres niveles:

$$\begin{aligned}
&\text{(i) Datos:} && Y_k \mid \boldsymbol{\beta}, \phi_k \overset{\text{ind}}{\sim} \text{Poisson}(E_k R_k), \\
& && \ln R_k = \boldsymbol{x}_k^\top \boldsymbol{\beta} + \phi_k, \\
&\text{(ii) Proceso:} && \boldsymbol{\phi} \mid \tau^2, \rho \;\sim\; N_K\big(\mathbf{0},\; \tau^2 Q(\rho)^{-1}\big), \\
& && Q(\rho) \text{ construida a partir de } W, \\
&\text{(iii) Hiperpar.:} && \boldsymbol{\beta} \sim p(\boldsymbol{\beta}),\quad \tau^2 \sim p(\tau^2),\quad \rho \sim p(\rho).
\end{aligned} \tag{3}$$

Los niveles se relacionan por condicionamiento: los datos dependen de $\boldsymbol{\beta}$ y de $\boldsymbol{\phi}$, y $\boldsymbol{\phi}$ depende de (τ^2, ρ),

$$(\tau^2, \rho) \;\longrightarrow\; \boldsymbol{\phi} \;\longrightarrow\; \boldsymbol{Y} \;\longleftarrow\; \boldsymbol{\beta},$$

y la distribución conjunta es el producto de las tres piezas (Banerjee et al., 2014, cap. 6):

$$\begin{aligned}
p(\boldsymbol{y}, \boldsymbol{\phi}, \boldsymbol{\beta}, \tau^2, \rho) = {} & \underbrace{\prod_{k=1}^{K} p(y_k \mid \boldsymbol{\beta}, \phi_k)}_{\text{(i)}} \; \underbrace{p(\boldsymbol{\phi} \mid \tau^2, \rho)}_{\text{(ii)}} \\
& \times \underbrace{p(\boldsymbol{\beta})\, p(\tau^2)\, p(\rho)}_{\text{(iii)}}.
\end{aligned} \tag{4}$$

Dado $\boldsymbol{\phi}$, los conteos son independientes; la dependencia espacial entra solo por el nivel (ii), porque ϕ_k y ϕ_j están correlacionados cuando $Q(\rho)^{-1}$ tiene entradas fuera de la diagonal. Al integrar $\boldsymbol{\phi}$, los Y_k quedan marginalmente dependientes y sobredispersos: $\operatorname{Var}(Y_k) = \mathbb{E}(Y_k) + E_k^2 e^{2\boldsymbol{x}_k^\top \boldsymbol{\beta}} \operatorname{Var}(e^{\phi_k}) > \mathbb{E}(Y_k)$. Con $\phi_k \equiv 0$ el modelo se reduce a la regresión Poisson log-lineal con *offset* $\ln E_k$, y para un aumento ξ en la covariable j el riesgo se multiplica por $RR_j = e^{\beta_j \xi}$.

La posterior no tiene una forma conocida. Por (4), $p(\boldsymbol{\phi}, \boldsymbol{\beta}, \tau^2, \rho \mid \boldsymbol{y})$ es proporcional a un producto de núcleos Poisson y normales. En ϕ_k, por ejemplo, el núcleo es $\exp\{y_k \phi_k - E_k e^{\boldsymbol{x}_k^\top \boldsymbol{\beta} + \phi_k} - c_k(\phi_k - m_k)^2\}$, con $c_k = (\rho n_k + 1 - \rho)/(2\tau^2)$, que no corresponde a ninguna familia estándar porque combina un término lineal, uno exponencial y uno cuadrático en ϕ_k. La constante de normalización es una integral de dimensión $K + p + 2$ sin solución analítica, por lo que la posterior se aproxima por simulación (MCMC).

2.4. La priori CAR y el modelo de Leroux

La priori CAR es la pieza que hace *espacial* al modelo: sin ella, los ϕ_k serían efectos independientes. Escribir directamente una distribución conjunta para K efectos correlacionados es difícil; resulta más natural especificar cómo se comporta cada región *dados sus vecinos*. Por eso el nivel (ii) se define de forma *condicional*, y el siguiente resultado garantiza que esas K condicionales determinan una única conjunta.

Definición 4 (Modelo autorregresivo condicional, CAR)**.** $\boldsymbol{\phi}$ sigue un CAR gaussiano si $\phi_k \mid \boldsymbol{\phi}_{-k} \sim N\big(\sum_{i\neq k} b_{ki}\phi_i,\ \sigma_k^2\big)$, $k = 1, \ldots, K$. Por el lema de Brook (Besag, 1974), si $B = (b_{ki})$ y $M = \operatorname{diag}(\sigma_k^2)$ cumplen $b_{ki}\sigma_i^2 = b_{ik}\sigma_k^2$, estas condicionales determinan una única conjunta $\boldsymbol{\phi} \sim N_K\big(\mathbf{0}, (I-B)^{-1}M\big)$, propia si $M^{-1}(I-B)$ es definida positiva.

Definición 5 (CAR de Leroux)**.** Leroux et al. (2000) toman, con $\tau^2 > 0$ y $\rho \in [0, 1)$,

$$\begin{aligned} \phi_k \mid \boldsymbol{\phi}_{-k} &\sim N\!\left(m_k,\ \frac{\tau^2}{\rho\, n_k + 1 - \rho}\right), \\ m_k = \underbrace{\frac{\rho\, n_k}{\rho\, n_k + 1 - \rho}}_{\in[0,1)}\ \bar{\phi}_{\partial k}, &\qquad \bar{\phi}_{\partial k} = \frac{1}{n_k}\sum_{i} w_{ki}\phi_i, \end{aligned} \tag{5}$$

lo que equivale a la conjunta normal multivariada con matriz de precisión $\tau^{-2}Q(\rho)$, $Q(\rho) = \rho(D_W - W) + (1-\rho)I_K$:

$$\begin{aligned} p(\boldsymbol{\phi} \mid \tau^2, \rho) &= \frac{|Q(\rho)|^{1/2}}{(2\pi\tau^2)^{K/2}} \exp\Big\{ -\frac{\boldsymbol{\phi}^\top Q(\rho)\boldsymbol{\phi}}{2\tau^2} \Big\}, \\ |Q(\rho)| &= \prod_{i=1}^{K} (\rho\lambda_i + 1 - \rho), \end{aligned} \tag{6}$$

donde $\lambda_i \geq 0$ son los valores propios de $D_W - W$.

La equivalencia se verifica completando el cuadrado en ϕ_k dentro de $\boldsymbol{\phi}^\top Q(\rho)\boldsymbol{\phi}$. Así, la *forma* de la priori es una normal multivariada cuya matriz de precisión se arma con el mapa: $Q_{kk} = \rho n_k + 1 - \rho$, $Q_{kj} = -\rho$ si k y j son vecinos y $Q_{kj} = 0$ si no lo son. La media condicional (5) es una fracción del promedio de los vecinos, y ρ controla esa fracción:

- $\rho = 0$: $Q = I_K$ y $\phi_k \overset{\text{iid}}{\sim} N(0, \tau^2)$, efectos independientes (solo sobredispersión);
- $\rho \to 1$: $m_k \to \bar{\phi}_{\partial k}$ y $\operatorname{Var}(\phi_k \mid \boldsymbol{\phi}_{-k}) \to \tau^2/n_k$, el CAR intrínseco de Besag (1974), cuya precisión $D_W - W$ es singular (priori impropia).

Para $\rho < 1$, $Q(\rho)$ es definida positiva y la priori es propia. La ventaja del modelo de Leroux es que ρ se estima con los datos en lugar de imponer de antemano una dependencia fuerte (Lee, 2011): a diferencia del CAR intrínseco, que corresponde a $\rho = 1$ y fija una dependencia espacial máxima, permite que los datos indiquen si la dependencia es fuerte o débil. Por esta razón, y porque es el modelo usado por Polo et al. (2022), es el que se adopta en este trabajo.

2.5. Préstamo de información (*shrinkage*)

El efecto conjunto de los niveles (i) y (ii) se ve en una aproximación normal. Para y_k moderado, $z_k = \ln(y_k/E_k) - \boldsymbol{x}_k^\top\boldsymbol{\beta}$ es aproximadamente $N(\phi_k, 1/y_k)$ (método delta). Combinando esta verosimilitud con la priori condicional (5), que es normal, se obtiene el resultado normal–normal conjugado (Gelman et al., 2013, cap. 5; Banerjee et al., 2014, cap. 6):

$$\begin{aligned} \mathbb{E}(\phi_k \mid \boldsymbol{\phi}_{-k}, \boldsymbol{y}) &\approx w_k\, z_k + (1 - w_k)\, m_k, \\ w_k &= \frac{y_k}{y_k + (\rho n_k + 1 - \rho)/\tau^2} \in (0, 1). \end{aligned} \tag{7}$$

La estimación de cada región es un promedio ponderado entre lo que dicen sus propios datos (z_k) y lo que dicen sus vecinos (m_k). El peso w_k depende de la precisión de cada fuente: una región con muchas muertes (y_k grande) tiene $w_k \approx 1$ y conserva su valor observado, mientras que una región con pocas muertes tiene w_k pequeño y su estimación se **encoge** hacia el promedio de sus vecinos. Así el modelo resuelve los dos problemas de la Sección 2.2: estabiliza los riesgos de regiones con pocos datos y aprovecha la dependencia espacial. Con $\rho = 0$ ($m_k = 0$) el encogimiento es hacia la media global.

2.6. Estimación por MCMC y diagnóstico

Como la posterior no tiene forma cerrada, se construye una cadena de Markov cuya distribución estacionaria es $p(\boldsymbol{\phi}, \boldsymbol{\beta}, \tau^2, \rho \mid \boldsymbol{y})$ (Gelman et al., 2013). En el esquema **Metropolis dentro de Gibbs**, cada bloque se actualiza desde su distribución condicional completa: si esta tiene forma conocida, se muestrea directamente (paso de Gibbs); si no, se propone $\theta^* \sim N(\theta^{(t)}, s^2)$ y se acepta con probabilidad $\alpha = \min\{1,\ p(\theta^* \mid \cdot)/p(\theta^{(t)} \mid \cdot)\}$ (paso de Metropolis), en el que la constante de normalización se cancela.

Definición 6 (Diagnósticos de convergencia)**.** Con m cadenas de longitud n, sea $\bar{s}^2$ el promedio de las varianzas dentro de las cadenas y $B = \frac{n}{m-1}\sum_{c=1}^{m}(\bar{\theta}_c - \bar{\theta})^2$ la varianza entre cadenas:

$$\begin{aligned} \hat{R} &= \sqrt{\frac{\frac{n-1}{n}\bar{s}^2 + \frac{1}{n}B}{\bar{s}^2}}, \qquad n_{\text{ef}} = \frac{mn}{1 + 2\sum_{l\geq 1}\varrho_l}, \\ z_G &= \frac{\bar{\theta}_A - \bar{\theta}_B}{\sqrt{\widehat{\operatorname{Var}}(\bar{\theta}_A) + \widehat{\operatorname{Var}}(\bar{\theta}_B)}}, \end{aligned} \tag{8}$$

donde ϱ_l es la autocorrelación de orden l y $\bar{\theta}_A, \bar{\theta}_B$ son las medias del primer 10 % y del último 50 % de la cade-

na (Geweke, 1992). Se acepta convergencia si $\hat{R} < 1.1$ y $|z_G| < 2$.

Definición 7 (Criterio de información de la devianza)**.** Con $D(\boldsymbol{\theta}) = -2\ln p(\boldsymbol{y} \mid \boldsymbol{\theta})$, $\bar{D} = \mathbb{E}[D(\boldsymbol{\theta}) \mid \boldsymbol{y}]$ y $\hat{\boldsymbol{\theta}}$ la media posterior, $p_D = \bar{D} - D(\hat{\boldsymbol{\theta}})$ es el número efectivo de parámetros y DIC $= \bar{D} + p_D$ (Spiegelhalter et al., 2002); menor DIC indica mejor balance entre ajuste y complejidad.

Definición 8 (Índice de Moran)**.** Para valores $r_1, \ldots, r_K$ (p. ej., residuos) con media $\bar{r}$, el índice de Moran (1950) es

$$I = \frac{K}{\sum_{k,j} w_{kj}} \cdot \frac{\sum_{k,j} w_{kj}(r_k - \bar{r})(r_j - \bar{r})}{\sum_k (r_k - \bar{r})^2}, \qquad \mathbb{E}[I \mid H_0] = -\frac{1}{K-1}. \tag{9}$$

$I > 0$ indica que regiones vecinas tienen valores similares e $I < 0$ que tienden a ser opuestos. Bajo H_0 de independencia espacial los valores son intercambiables, y los valores p se obtienen por permutaciones: $p_+ = \frac{1}{M}\sum_m \mathbb{I}\{I^{(m)} \geq I_{\text{obs}}\}$ para autocorrelación positiva y $p_- = \frac{1}{M}\sum_m \mathbb{I}\{I^{(m)} \leq I_{\text{obs}}\}$ para negativa. La sobredispersión de un GLM Poisson se mide con $\hat{\varphi} = \frac{1}{K-p}\sum_k r_k^2$, con $r_k = (Y_k - \hat{\mu}_k)/\sqrt{\hat{\mu}_k}$; bajo el modelo, $\hat{\varphi} \approx 1$.

3. Datos y metodología

3.1. Datos

Se usaron los datos de Polo et al. (2022), publicados en las Tablas 1 y 2 del artículo, para las $K = 33$ unidades administrativas de Colombia (32 departamentos y Bogotá D.C.) entre el 16 de marzo y el 4 de octubre de 2020. Para el departamento k, Y_k son las muertes por COVID-19 reportadas por el INS (2020). Los esperados se calcularon con (2), tomando como población en riesgo los casos resueltos, $N_k = Y_k + \mathcal{R}_k$, y como tasa global la letalidad nacional:

$$E_k = (Y_k + \mathcal{R}_k)\,\text{NCFR}, \qquad \text{SCFR}_k = \frac{Y_k}{E_k}, \qquad \text{NCFR} = \frac{\sum_k Y_k}{\sum_k (Y_k + \mathcal{R}_k)} = 0.034, \tag{10}$$

donde $\mathcal{R}_k$ son los recuperados. El SCFR (letalidad estandarizada), estimador de máxima verosimilitud de R_k en (3), varía entre 0.41 (Vaupés) y 1.95 (Córdoba). Se verificó que el total de muertes coincide con el reportado (28 882). Las covariables son las cinco dimensiones del IPM de fuente censal 2018 (DANE, 2020): salud (HMPI), educación (EMPI), trabajo (WMPI), vivienda (DMPI) y niñez y juventud (YMPI), en puntos porcentuales. Las cuatro últimas tienen correlaciones entre 0.82 y 0.95. La matriz W se construyó por contigüidad y se verificó con el mapa de Colombia (4.42 vecinos en promedio). San Andrés, por ser una isla, no tiene vecinos ($n_k = 0$); en el modelo de Leroux esto no genera problemas, pues su efecto queda con media condicional 0 y varianza finita $\tau^2/(1-\rho)$, de modo que se encoge hacia la media global. Con el CAR intrínseco ($\rho = 1$), en cambio, su varianza no estaría definida.

3.2. Especificación del modelo

$$\begin{aligned} Y_k \mid \mu_k &\overset{\text{ind}}{\sim} \text{Poisson}(\mu_k), \qquad k = 1, \ldots, 33, \\ \ln \mu_k &= \ln E_k + \beta_0 + \beta_1 \text{HMPI}_k + \beta_2 \text{EMPI}_k \\ &\quad + \beta_3 \text{WMPI}_k + \beta_4 \text{DMPI}_k + \beta_5 \text{YMPI}_k + \phi_k, \\ \boldsymbol{\phi} \mid \tau^2, \rho &\sim N_{33}\big(\mathbf{0}, \tau^2 Q(\rho)^{-1}\big), \quad \boldsymbol{\beta} \sim N_6(\mathbf{0}, 10^5 I_6), \\ \tau^2 &\sim \text{Inv-Gamma}(1,\, 0.01), \quad \rho \sim \text{U}(0,1). \end{aligned} \tag{11}$$

Las prioris de τ^2 y ρ son las del artículo; como este no reporta los hiperparámetros de la priori de $\boldsymbol{\beta}$, se usó el valor por defecto de CARBayes (Lee, 2013). Las covariables se centraron en su media, lo que no altera las pendientes. Con $\eta_k = \ln \mu_k$, la posterior es

$$\begin{aligned} p(\boldsymbol{\beta}, \boldsymbol{\phi}, \tau^2, \rho \mid \boldsymbol{y}) \propto\; & e^{\sum_k (Y_k \eta_k - e^{\eta_k})}\, e^{-\frac{\boldsymbol{\beta}^\top \boldsymbol{\beta}}{2 \cdot 10^5}}\, |Q(\rho)|^{\frac{1}{2}} \\ & \times (\tau^2)^{-\frac{33}{2}} e^{-\frac{\boldsymbol{\phi}^\top Q(\rho) \boldsymbol{\phi}}{2\tau^2}}\, (\tau^2)^{-2} e^{-\frac{0.01}{\tau^2}} \\ & \times \mathbb{I}\{0 < \rho < 1\}, \end{aligned} \tag{12}$$

y sus condicionales completas son

$$\begin{aligned} p(\boldsymbol{\beta} \mid \cdot) &\propto \exp\Big\{ \textstyle\sum_k \big(Y_k \boldsymbol{x}_k^\top \boldsymbol{\beta} - E_k e^{\boldsymbol{x}_k^\top \boldsymbol{\beta} + \phi_k}\big) - \frac{\boldsymbol{\beta}^\top \boldsymbol{\beta}}{2 \cdot 10^5} \Big\}, \\ p(\phi_k \mid \cdot) &\propto \exp\Big\{ Y_k \phi_k - E_k e^{\boldsymbol{x}_k^\top \boldsymbol{\beta} + \phi_k} - \tfrac{\rho n_k + 1 - \rho}{2\tau^2}(\phi_k - m_k)^2 \Big\}, \\ m_k &= \frac{\rho \sum_i w_{ki} \phi_i}{\rho n_k + 1 - \rho}, \\ \tau^2 \mid \cdot &\sim \text{Inv-Gamma}\Big(1 + \tfrac{33}{2},\; 0.01 + \tfrac{1}{2}\boldsymbol{\phi}^\top Q(\rho) \boldsymbol{\phi}\Big), \\ p(\rho \mid \cdot) &\propto \prod_i (\rho \lambda_i + 1 - \rho)^{\frac{1}{2}} e^{-\frac{\boldsymbol{\phi}^\top Q(\rho) \boldsymbol{\phi}}{2\tau^2}}. \end{aligned} \tag{13}$$

La de τ^2 se obtiene multiplicando $(\tau^2)^{-a-1} e^{-b/\tau^2}$ por $(\tau^2)^{-K/2} e^{-\boldsymbol{\phi}^\top Q \boldsymbol{\phi}/2\tau^2}$. Así, τ^2 se actualizó por Gibbs y $\boldsymbol{\beta}$, cada ϕ_k y ρ por Metropolis con propuestas normales simétricas.

3.3. Estimación y análisis

Se corrieron tres cadenas de 300 000 iteraciones, con *burn-in* de 50 000 y *thinning* de 250 (3 000 muestras); durante el *burn-in* el tamaño de las propuestas se ajustó para obtener tasas de aceptación entre 20 % y 50 %. Se evaluó la convergencia con trazas, $\hat{R}$, n_{ef} y Gewe-

ke. Además, se ajustaron el GLM Poisson frecuentista y su versión bayesiana sin efectos aleatorios, se calculó el índice de Moran de sus residuos con 10 000 permutaciones, se compararon los modelos con el DIC y se repitió el modelo con $\tau^2 \sim$ Inv-Gamma$(0.001, 0.001)$ y Inv-Gamma$(1, 1)$. Los riesgos relativos se calcularon como $RR_j^{(s)} = e^{\beta_j^{(s)} \xi_j}$, con ξ_j la desviación estándar de la covariable, y $P(RR_j > 1 \mid \boldsymbol{y}) \approx \frac{1}{S} \sum_s \mathbb{I}\{RR_j^{(s)} > 1\}$. El algoritmo fue programado por la autora en Python; el cuaderno `Proyecto_Bayesiana_Polo2022.ipynb` y los datos (`datos_polo2022.csv`) se entregan con este informe y reproducen todas las tablas y figuras.

4. Resultados

4.1. Sobredispersión y dependencia espacial

El GLM Poisson presentó una fuerte sobredispersión: el cociente entre el estadístico χ^2 de Pearson y sus grados de libertad fue 54.9, cuando bajo el modelo Poisson debería estar cerca de 1. En consecuencia, aunque todos los coeficientes del GLM resultaron significativos ($p < 0.05$), sus errores estándar están fuertemente subestimados: al corregirlos por sobredispersión (cuasi-Poisson), ninguna dimensión es significativa al 5 %. Esto justifica incluir un efecto aleatorio por departamento.

La letalidad estandarizada presenta autocorrelación espacial positiva ($I = 0.162$, $p = 0.045$): hay grupos de departamentos vecinos con letalidad alta en el Caribe y baja en el oriente del país (Figura 1A). Sin embargo, los residuos del GLM muestran autocorrelación **negativa** ($I = -0.258$, $p = 0.008$): después de controlar por la pobreza, los departamentos con más muertes de las predichas, como Córdoba y Santander, están rodeados de departamentos con menos muertes de las predichas, como Antioquia, Bolívar, Sucre y Boyacá (Figura 1B). Esto contrasta con la autocorrelación positiva de los residuos reportada por Polo et al. (2022).

4.2. Modelo CAR de Leroux

Las cadenas convergieron: $\hat{R} \leq 1.002$ y tamaños efectivos mayores a 490 en todos los parámetros, y Geweke entre -2 y 2 salvo en el intercepto ($z = 3.0$, con $\hat{R} = 1.000$ y tamaño efectivo 2152). Las tasas de aceptación fueron 30–33 % ($\boldsymbol{\beta}$), 40 % (ϕ_k) y 35–46 % (ρ).

La única dimensión cuyo intervalo de credibilidad no contiene el 0 es la educativa. La de vivienda tiene un coeficiente negativo con un intervalo que apenas alcanza el 0, y las de salud, trabajo y niñez y juventud no muestran un efecto claro (Tabla 1 y Figura 2). La posterior de ρ se concentra cerca de 0, frente a la priori uniforme, lo que indica una dependencia espacial débil.

La Tabla 2 presenta los riesgos relativos para un aumento de una desviación estándar en cada dimensión. Un aumento de 4.2 puntos en la pobreza educativa se asocia con un aumento del 68 % en el riesgo de morir por COVID-19, con una probabilidad posterior de 0.99 de que el efecto sea positivo; este valor coincide con el del artículo (1.69). En cambio, el riesgo relativo de la vivienda es menor que 1 (0.65), opuesto al principal resultado del artículo (1.74).

4.3. Comparación de modelos y sensibilidad a la priori

El GLM y el Poisson bayesiano sin efectos aleatorios producen coeficientes prácticamente iguales, como se espera con una priori vaga (Tabla 3). Al incluir los efectos aleatorios, el DIC baja de 1677.1 a 312.7, valor cercano al reportado por Polo et al. (2022) (320.79), y los intervalos se amplían unas seis veces. Con las tres prioris para τ^2, las medianas de los coeficientes casi no cambian, aunque con la priori Inv-Gamma(1, 1) el efecto educativo deja de ser claramente positivo. En cambio, ρ varía entre 0.18 y 0.49, lo que indica que con 33 departamentos los datos aportan poca información sobre la dependencia espacial.

4.4. Riesgo por departamento

Los riesgos relativos estimados reproducen de cerca el SCFR observado (error absoluto medio de 0.018; Figura 3). Catorce departamentos tienen una probabilidad posterior mayor o igual a 0.99 de presentar un riesgo superior al nacional, encabezados por Córdoba (RR = 1.94), Norte de Santander (1.80) y Magdalena (1.57), y trece tienen una probabilidad menor o igual a 0.03, entre ellos Vaupés (0.48), Vichada (0.51) y Guainía (0.53). Los departamentos con pocas muertes se contraen hacia 1 (encogimiento). Estos riesgos coinciden con los reportados en el artículo en 31 de los 33 departamentos; las excepciones son Magdalena y Putumayo, justamente los dos departamentos cuyo SCFR publicado no coincide con el cociente entre muertes observadas y esperadas de su Tabla 1.

5. Discusión

5.1. Interpretación

Con los mismos datos, la replicación coincide con Polo et al. (2022) en el efecto positivo de la pobreza educativa y en la ausencia de efecto del trabajo, pero no reproduce el efecto de vivienda, salud y niñez y juventud. La explicación más probable es la alta correlación entre las dimensiones: los departamentos del oriente (Vichada, Guainía, Vaupés) tienen a la vez los valores más altos de pobreza en educación, trabajo, vivienda y niñez, y las letalidades más bajas, de modo que con 33 departamentos el modelo no logra separar el efecto de cada dimensión. De hecho, al ajustar cada dimensión por separado ninguna muestra un efecto claro, y el efecto educativo solo aparece cuando se incluyen las cinco, lo que obliga a interpretarlo con

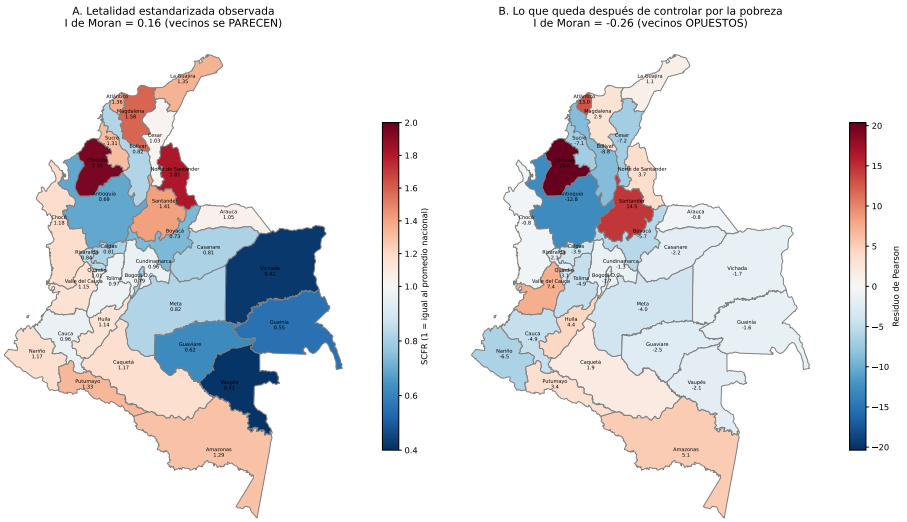


Figura 1: (A) Letalidad estandarizada observada. (B) Residuos de Pearson del modelo Poisson con las cinco dimensiones del IPM. San Andrés se omite por escala.

Tabla 1: Resumen posterior del modelo CAR de Leroux y comparación con la Tabla 3 de Polo et al. (2022).

	Este trabajo				Polo et al. (2022)
Parámetro	Mediana	IC 95 %	n efectivo	Geweke	Mediana (IC 95 %)
HMPI (salud)	0.030	(−0.099, 0.164)	513	0.12	0.142 (0.015, 0.214)
EMPI (educación)	0.122	(0.031, 0.209)	495	0.47	0.056 (0.011, 0.215)
WMPI (trabajo)	−0.011	(−0.122, 0.088)	533	0.60	−0.055 (−0.183, 0.097)
DMPI (vivienda)	−0.105	(−0.209, 0.004)	527	0.03	0.636 (0.228, 0.901)
YMPI (niñez)	−0.078	(−0.306, 0.167)	623	−0.09	0.060 (0.037, 0.534)
τ^2	0.115	(0.054, 0.274)	1988	−0.84	–
ρ	0.183	(0.008, 0.730)	2036	−1.24	0.612 (0.219, 0.782)

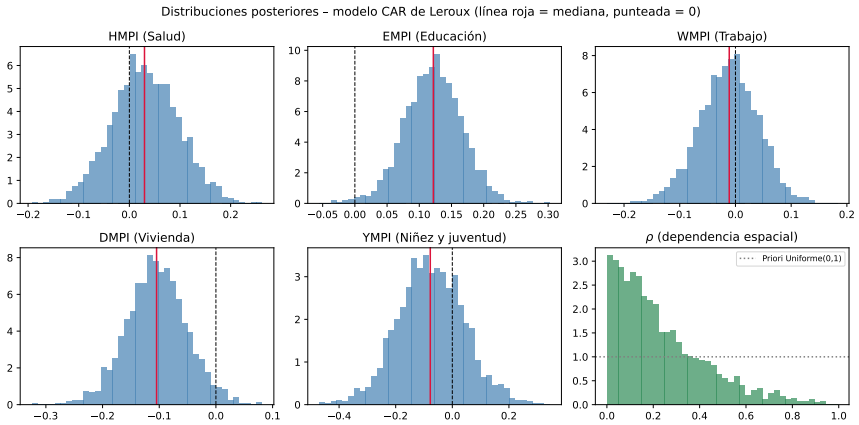


Figura 2: Distribuciones posteriores de los coeficientes y de ρ en el modelo CAR de Leroux. La línea roja indica la mediana y la punteada el 0; en ρ, la línea punteada es la priori uniforme.

Tabla 2: Riesgos relativos posteriores para un aumento de una desviación estándar (ξ) en cada dimensión.

		Este trabajo			Polo et al. (2022)
Dimensión	ξ	RR	IC 95 %	$P(RR > 1)$	RR (IC 95 %)
Educación	4.24	1.68	(1.14, 2.43)	0.99	1.69 (1.36, 5.94)
Salud	1.63	1.05	(0.85, 1.31)	0.68	1.16 (1.06, 2.04)
Trabajo	4.52	0.95	(0.58, 1.49)	0.41	1.02 (0.80, 3.06)
Niñez y juventud	1.78	0.87	(0.58, 1.35)	0.27	1.35 (1.08, 4.03)
Vivienda	4.07	0.65	(0.43, 1.02)	0.03	1.74 (1.54, 9.75)

Tabla 3: Comparación de modelos y sensibilidad a la priori de τ^2: mediana (IC 95 %) de los coeficientes de salud, educación y vivienda.

Modelo	HMPI	EMPI	DMPI	DIC	ρ
GLM Poisson	0.125 (0.106, 0.144)	0.084 (0.069, 0.099)	−0.073 (−0.088, −0.057)	–	–
Poisson bayesiano	0.125 (0.107, 0.144)	0.084 (0.069, 0.099)	−0.072 (−0.089, −0.057)	1677.1	–
CAR, IG(1, 0.01)	0.030 (−0.099, 0.164)	0.122 (0.031, 0.209)	−0.105 (−0.209, 0.004)	312.7	0.18
CAR, IG(0.001, 0.001)	0.037 (−0.103, 0.184)	0.120 (0.017, 0.214)	−0.097 (−0.205, 0.008)	312.5	0.25
CAR, IG(1, 1)	0.029 (−0.137, 0.194)	0.111 (−0.013, 0.234)	−0.102 (−0.244, 0.032)	312.7	0.49

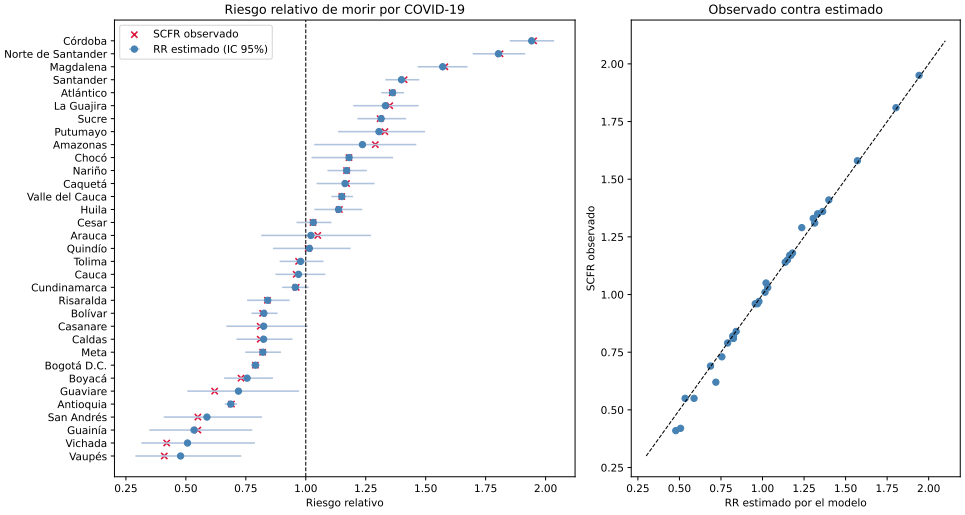


Figura 3: Izquierda: riesgo relativo estimado (mediana e IC 95 %) y SCFR observado por departamento. Derecha: SCFR observado contra riesgo estimado.

cautela.

La dependencia espacial resultó débil, y los residuos sin efectos aleatorios muestran un patrón de vecinos opuestos. Esto es consistente con Birchenall-Jiménez et al. (2025), quienes, con datos municipales de mortalidad, encontraron un parámetro de dependencia espacial negativo en 2020 ($\rho = -0.39$) y varios indicadores del IPM con asociaciones negativas. La mejora en el DIC del modelo CAR se debe, por tanto, más a capturar la heterogeneidad entre departamentos (la sobredispersión) que a la estructura espacial.

5.2. Contraste crítico con el artículo

Se verificó que las diferencias no se deben a los datos ni a la matriz de vecindad: los totales, el DIC y los riesgos por departamento coinciden con los publicados, y el GLM, que no usa W, ya produce un coeficiente negativo para vivienda. En cambio, se encontraron inconsistencias en el artículo: (i) los riesgos relativos de su Tabla 4 no se obtienen de los coeficientes de su Tabla 3 con la fórmula que declaran (para vivienda daría $e^{0.636\times4.07} \approx 13$, no 1.74, y trabajo tiene un coeficiente negativo con un riesgo relativo mayor que 1); (ii) la tabla del modelo sin efectos espaciales de su material suplementario es idéntica a la del modelo CAR, incluido ρ; y (iii) el SCFR publicado para Magdalena y Putumayo no coincide con sus datos. Además, no reporta los hiperparámetros de la priori de $\boldsymbol{\beta}$, la matriz W, el tratamiento de San Andrés, el tipo de residuo del índice de Moran ni el código. Una versión preliminar del estudio (Polo et al., 2020) excluía la dimensión de niñez y juventud para evitar colinealidad y reportaba efectos muy distintos (por ejemplo, salud: RR = 1.89), lo que refuerza que los resultados dependen mucho de las decisiones de modelado.

5.3. Limitaciones

En cuanto al **diseño**, el estudio es ecológico: una asociación entre departamentos no implica que las personas pobres tengan mayor riesgo individual de morir. En cuanto a los **datos**, los esperados no se ajustaron por edad, de modo que departamentos con poblaciones más envejecidas pueden mostrar mayor letalidad sin relación con la pobreza; además, la letalidad depende de la capacidad de diagnóstico, pues donde se realizan menos pruebas se detectan sobre todo los casos graves, lo que puede confundirse con el efecto de las dimensiones del IPM. En cuanto al **modelo**, con 33 áreas los intervalos son amplios y ρ es poco identificable; la alta correlación entre las dimensiones impide separar sus efectos; la sensibilidad se evaluó solo para la priori de τ^2 y no para la de $\boldsymbol{\beta}$, cuyos hiperparámetros el artículo no reporta; y no se evaluó la alternativa de conectar a San Andrés con algún departamento continental (por ejemplo, Bolívar, por sus vínculos de transporte), lo que podría modificar levemente la estimación de ρ. Finalmente, no se replicó la validación con datos de 2021, que el artículo no publica.

5.4. Aplicación en contextos reales

Frente a comparar directamente la letalidad observada (SCFR) de cada departamento, el modelo ofrece dos herramientas útiles para la vigilancia en salud pública. Primero, estabiliza las estimaciones de las áreas con pocos casos, cuya letalidad observada puede parecer extrema solo por azar; en estos datos el efecto fue pequeño, porque casi todos los departamentos registraron muchas muertes, pero sería relevante en análisis a nivel municipal. Segundo, entrega para cada departamento la probabilidad posterior de que su riesgo supere el nacional, $P(R_k > 1 \mid \boldsymbol{y})$, una medida directa para priorizar recursos: con ella, Córdoba, Norte de Santander y Magdalena aparecen como los departamentos prioritarios. Por esta razón, el mismo enfoque se usa para mapear otros eventos de salud por áreas, como las enfermedades transmitidas por vectores. No obstante, aplicar este patrón en futuras emergencias supone que se mantenga en el tiempo, algo que debería verificarse con datos posteriores, y los resultados no respaldan focalizar políticas en una dimensión específica de la pobreza, salvo, con cautela, la educativa.

6. Conclusiones

Este trabajo replicó el análisis de Polo et al. (2022) a partir de la información publicada. Se reconstruyó la base de datos de los 33 departamentos con las Tablas 1 y 2 del artículo, se verificó que los totales coincidieran con los reportados, se construyó la matriz de vecindad W y se comprobó con el mapa de Colombia, y se programó desde cero el algoritmo de Metropolis dentro de Gibbs para el modelo CAR de Leroux, con propuestas adaptativas y centrado de los efectos espaciales. Las cadenas convergieron ($\hat{R} \leq 1.002$), y el análisis se complementó con el GLM Poisson frecuentista, un modelo bayesiano sin efectos espaciales, el índice de Moran de los residuos y un análisis de sensibilidad a la priori de τ^2. La replicación fue **parcial**: se reprodujeron los datos, el ajuste global (DIC de 312.7 frente a 320.79) y los riesgos de 31 de los 33 departamentos, pero no las conclusiones sobre las covariables. Frente a las principales afirmaciones del artículo:

- **Pobreza y letalidad.** El artículo identifica la vivienda como el principal factor de riesgo (RR = 1.74), seguida de educación, niñez y juventud y salud. Aquí solo la educación mostró una asociación clara, con un riesgo relativo casi idéntico (1.68 frente a 1.69); la vivienda resultó negativa (0.65) y las demás dimensiones no mostraron efecto.
- **Dependencia espacial.** El artículo reporta una dependencia moderada ($\rho = 0.61$) y residuos con autocorrelación positiva. Aquí la dependencia fue débil ($\rho = 0.18$) y sensible a la priori (entre 0.18 y 0.49), y los residuos mostraron autocorrelación negativa.
- **Ajuste del modelo.** El artículo presenta su error de ajuste (0.012) como evidencia de precisión. Aquí

se obtuvo un error similar (0.018), pero este es esperable con un efecto aleatorio por departamento y no demuestra capacidad predictiva.

Las diferencias no se explican por los datos ni por la matriz W: el GLM, que no usa W, ya produce un coeficiente negativo para la vivienda. La causa más probable es la alta correlación entre las dimensiones del IPM (entre 0.82 y 0.95), que con 33 departamentos impide separar sus efectos, y que el propio estudio había reconocido en su versión preliminar al excluir la dimensión de niñez y juventud. A esto se suman inconsistencias internas del artículo: sus riesgos relativos no se obtienen de sus coeficientes con la fórmula que declaran, la tabla del modelo sin efectos espaciales del material suplementario repite la del modelo CAR, y el SCFR publicado de dos departamentos no coincide con sus datos.

La replicación completa tampoco fue posible por información que el artículo no reporta: los hiperparámetros de la priori de $\boldsymbol{\beta}$, la matriz de vecindad y el tratamiento de San Andrés, el tipo de residuo usado en el índice de Moran, el código y los datos de 2021 usados para validar el modelo. Cada uno de estos vacíos obligó a tomar una decisión propia, lo que limita la comparación y muestra que, sin esa información, un análisis bayesiano no puede verificarse por completo.

Desde el punto de vista metodológico, el trabajo muestra el valor del enfoque bayesiano jerárquico con pocas unidades de análisis: cuantifica la incertidumbre de todos los parámetros, suaviza las estimaciones inestables y evita las conclusiones espurias del GLM, que declaró significativas todas las dimensiones por subestimar los errores en presencia de sobredispersión. Al mismo tiempo, muestra que con 33 áreas la dependencia espacial queda débilmente identificada y que los resultados dependen de decisiones de modelado que deben reportarse. En conjunto, la evidencia indica que la relación entre pobreza multidimensional y letalidad por COVID-19 en Colombia es menos robusta de lo reportado, con la pobreza educativa como el único hallazgo consistente. Como trabajo futuro se propone ajustar los esperados por edad, trabajar a nivel municipal para ganar unidades de análisis, tratar la colinealidad entre las dimensiones (por ejemplo, con el IPM agregado o con prioris de regularización), evaluar la sensibilidad a la priori de $\boldsymbol{\beta}$ y a la definición de W, y extender el modelo a una versión espacio-temporal.

Referencias

Alkire, S., & Santos, M. E. (2014). Measuring acute poverty in the developing world: Robustness and scope of the multidimensional poverty index. *World Development, 59*, 251–274. https://doi.org/10.1016/j.worlddev.2014.01.026

Banerjee, S., Carlin, B. P., & Gelfand, A. E. (2014). *Hierarchical modeling and analysis for spatial data* (2.ª ed.). Chapman and Hall/CRC.

Besag, J. (1974). Spatial interaction and the statistical analysis of lattice systems. *Journal of the Royal Statistical Society: Series B, 36*(2), 192–236.

Birchenall-Jiménez, C., Jiménez-Barbosa, W. G., Riascos-Ochoa, J., & Cosenz, F. (2025). Exploring spatial inequalities in COVID-19 mortality and their association with multidimensional poverty in Colombia: A spatial analysis study. *International Journal of Public Health, 69*, 1607820. https://doi.org/10.3389/ijph.2024.1607820

Departamento Administrativo Nacional de Estadística [DANE]. (2020). *Medida de pobreza multidimensional de fuente censal 2018*. https://www.dane.gov.co

Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., & Rubin, D. B. (2013). *Bayesian data analysis* (3.ªed.). Chapman and Hall/CRC.

Geweke, J. (1992). Evaluating the accuracy of sampling-based approaches to the calculation of posterior moments. En J. M. Bernardo, J. O. Berger, A. P. Dawid y A. F. M. Smith (Eds.), *Bayesian statistics 4* (pp. 169–193). Oxford University Press.

Instituto Nacional de Salud. (2020). *COVID-19 en Colombia*. https://www.ins.gov.co

Lee, D. (2011). A comparison of conditional autoregressive models used in Bayesian disease mapping. *Spatial and Spatio-temporal Epidemiology, 2*(2), 79–89.

Lee, D. (2013). CARBayes: An R package for Bayesian spatial modeling with conditional autoregressive priors. *Journal of Statistical Software, 55*(13), 1–24. https://doi.org/10.18637/jss.v055.i13

Leroux, B. G., Lei, X., & Breslow, N. (2000). Estimation of disease rates in small areas: A new mixed model for spatial dependence. En M. E. Halloran y D. Berry (Eds.), *Statistical models in epidemiology, the environment, and clinical trials* (pp. 179–191). Springer.

Moran, P. A. P. (1950). Notes on continuous stochastic phenomena. *Biometrika, 37*(1/2), 17–23.

Polo, G., Mera Acosta, C., Soler-Tovar, D., Porras Villamil, J. F., Polanco Palencia, N., Penagos, M., Meza Martinez, J., Bobadilla, J. N., Martin, L. V., Durán, S., Rodriguez, M., Meza Carvajalino, C., Villamil, L. C., & Benavides Ortiz, E. (2020). *Bayesian spatio-temporal modeling of COVID-19: Inequalities on case-fatality risk* [Preprint]. medRxiv. https://doi.org/10.1101/2020.08.18.20171074

Polo, G., Soler-Tovar, D., Villamil Jimenez, L. C., Benavides-Ortiz, E., & Mera Acosta, C. (2022). Bayesian spatial modeling of COVID-19 case-fatality rate inequalities. *Spatial and Spatio-temporal Epidemiology, 41*, 100494. https://doi.org/10.1016/j.sste.2022.100494

Spiegelhalter, D. J., Best, N. G., Carlin, B. P., & van der Linde, A. (2002). Bayesian measures of model complexity and fit. *Journal of the Royal Statistical Society: Series B, 64*(4), 583–639.